

Puccettoni · Fort Lauderdale, FL

Atendimento por Voz com IA & Ecossistema de CX

Brief executivo — arquitetura validada e roadmap de construção

A tese, em uma frase: primeiro provamos que a IA consegue atender e capturar pedidos reais no pico, no idioma do cliente, sem perder venda. Depois conectamos o Toast. Depois otimizamos custo e latência. Só então transformamos isso em plataforma.

Objetivo central: recuperar os pedidos por telefone que hoje se perdem no horário de pico, em múltiplos idiomas, com confiabilidade — sem depender de delivery com comissão e sem travar a operação.

Documento: suficiente para construir a plataforma e o ecossistema de CX. **Leitor:** Marco (engenheiro de software, hoje à frente da pizzeria).

Operação: 3801 Davie Blvd, Fort Lauderdale, FL 33312 · (754) 307-4992 · pickup-first.

01 — SUMÁRIO EXECUTIVO

O que estamos construindo, e por quê

Um **atendente de voz com IA** que atende o telefone da Puccettoni, conversa no idioma do cliente, monta o pedido, confirma e o entrega à cozinha — funcionando **desde antes** de qualquer integração com o ponto de venda. O sistema nasce resolvendo um problema concreto: **ligações perdidas no pico** viram receita perdida, e uma clientela multilíngue (inglês, espanhol, crioulo haitiano, português, italiano) é mal atendida por menus de delivery genéricos e comissionados.

A aposta é deliberadamente enxuta. Em vez de construir uma plataforma genérica de cara, validamos o caminho mais curto até a receita: uma chamada real, um pedido estruturado, entregue à operação. A sofisticação — Toast nativo, otimização de custo, multi-loja — vem **depois** da prova de valor, na ordem certa de risco.

ESTADO ATUAL — A FASE 0 ESTÁ PRATICAMENTE PRONTA

Já existe, testado e funcionando offline: backend TypeScript com as 5 ferramentas de voz (disponibilidade, preço, envio do pedido, transferência, SMS), reconhecimento difuso do cardápio, cálculo de total + tempo de preparo e guarda de horário; **camada Toast completa** (auth · menus · config · prices · orders) com **fallback automático** para o bridge; simulador sem credenciais (npm run sim), 13 testes e build limpos; system-prompt.md otimizado (uma frase por turno + frase-ponte multilíngue); sync-tunnel.mjs e ARCHITECTURE.md. Falta ligar números, créditos e fazer a primeira chamada real.

02 — O PROBLEMA E A OPORTUNIDADE

Onde a receita vaza hoje

REALIDADE HOJE	O QUE O SISTEMA MUDA
Telefone toca no pico e ninguém atende	A IA atende em um toque, sempre, em paralelo à cozinha — o pedido não se perde.
Clientela multilíngue (Broward) mal atendida	Conversa nativa em EN / ES / crioulo haitiano / PT / IT — um diferencial real na região.
Delivery de terceiros cobra comissão	Canal próprio de receita: o pedido entra direto, sem intermediário comissionado.
Equipe parada no telefone em vez de na operação	A IA cuida da captura; a equipe foca em produzir e atender no balcão.

O ganho não depende de tecnologia sofisticada — depende de **capturar a chamada e estruturar o pedido com confiabilidade**. É isso que o MVP prova primeiro.

03 — ARQUITETURA VALIDADA

A stack e as decisões por trás dela

Cada escolha vem de um trade-off discutido, não de default — e é medida contra os critérios de sucesso (seção 06).



O loop da conversa (linha 1) e o caminho do pedido (linha 2). Se o Toast falhar ou ainda não estiver conectado, o pedido cai automaticamente no bridge — nada se perde.

CAMADA	PAPEL	DECISÃO DESTA VERSÃO
Vapi	Orquestração da chamada em tempo real: assistant, ferramentas, barge-in, fluxo conversacional.	Usar a camada gerenciada em vez de reconstruir o loop de voz à mão. É o caminho de menor risco e menor tempo até a primeira chamada real.
Deepgram	STT (fala → texto) em streaming.	Transcrição rápida e multilíngue; reduz a latência percebida no início do turno.
LLM	Cérebro conversacional: entende intenção e chama ferramentas.	A/B comparando Claude e GPT como motor principal , priorizando latência, estabilidade e custo. Os fatos (cardápio, preço, horário) vêm sempre das ferramentas, nunca da memória do modelo.
ElevenLabs Multilingual v2	Voz natural, multilíngue.	Default: cascata + ElevenLabs — não Realtime — por causa do multilíngue (crioulo/PT). Realtime entra como A/B medido nesses idiomas (ver decisão abaixo).
Backend TS	Menu, carrinho, preço, disponibilidade, confirmação, handoff.	Caminho crítico do pedido em código enxuto. Endpoint único: /vapi/tool-calls.
Toast Orders API	Criar o pedido real no POS/KDS.	Integração-alvo via acesso custom/standard pela conta do Marco (não a fila de partner). O carrinho é nosso; o preço oficial vem do Toast.
Bridge	Rede de segurança operacional.	Pedido estruturado para a operação. Hoje: SMS (hook pronto para impressora); e-mail/WhatsApp/painel são plug-in.
Host US-East	Onde o backend roda.	Host estável perto da telefonia/usuários, URL fixa — não o tunnel descartável.
n8n (opcional)	Automação assíncrona.	Fora do caminho crítico: follow-up, CRM, alertas, relatórios. Nunca no turno em que o cliente espera.

A DECISÃO MAIS IMPORTANTE — VOZ MULTILÍNGUE ACIMA DE LATÊNCIA PURA

No Vapi, **“GPT-4o Realtime + ElevenLabs” não coexiste**: o Realtime é speech-to-speech nativo e só usa vozes da OpenAI. Realtime ganha em latência; a cascata (Deepgram → LLM → ElevenLabs) mantém a melhor voz e a melhor cobertura multilíngue — **inclusive crioulo haitiano e português**, o diferencial da Puccettoni em Broward. Por isso o default é cascata + ElevenLabs. O A/B Realtime-vs-cascata fica **em aberto, medido no crioulo e no português** (não no inglês) — é aí que a voz move conclusão e satisfação.

LATÊNCIA — A META É PARECER RÁPIDO NO TURNO DO PEDIDO

O turno do pedido (com /prices + POST no Toast) leva ~1 s+ **não importa a voz** — o gargalo é o Toast, não o loop de fala. Por isso a IA diz uma **frase-ponte no idioma do cliente** (“só um segundo, fechando seu total”) antes de chamar a ferramenta, com streaming em tudo. Mede-se o **time-to-first-audio** e a duração da chamada ao Toast, não só o tempo total.

04 — EXPERIÊNCIA DO CLIENTE (CX)

Como soa uma ligação — e como o sistema não derruba a marca

Jornada principal (pickup)

- Atende em um toque com saudação curta bilíngue (EN/ES) e **detecta o idioma** do cliente.
- Conversa no idioma do cliente, **uma frase por turno** — telefone, não e-mail.
- Monta o pedido item a item, confirmando cada item; oferece bebida e sobremesa **uma vez**, sem insistir.
- Verifica disponibilidade real (check_availability); **nunca inventa** item ou preço.
- Antes de fechar o total, diz a frase-ponte e chama price_cart (total oficial).
- Lê o pedido de volta — itens, total, horário de retirada, nome — e pede **confirmação clara**.
- Envia (submit_order → Toast ou bridge), confirma número e ETA, SMS opcional.
- Pagamento **na retirada** — nunca coleta número de cartão.

Casos de borda que o sistema já trata

SITUAÇÃO	COMPORTAMENTO
Item indisponível (86)	Avisa e oferece alternativa; não promete o que não há.
Fora do horário	Oferece agendar para a próxima janela ou recado/handoff. Horário é validado por nós.
Fora do escopo / “quero falar com alguém”	Transferência para humano (transfer_to_human).
Cliente troca de idioma no meio	A IA acompanha e troca junto.
Falha de ferramenta / Toast	Bridge automático; o cliente é tranquilizado; o pedido não se perde .

PRINCÍPIOS DE CX (DEFESA DA MARCA)

Turnos curtos e humanos · calor italiano com parcimônia · confirmação obrigatória antes de enviar · nunca inventar preço/cardápio · handoff humano sempre fácil · pickup-first e pagamento na retirada · piloto inicial em horários controlados para proteger a experiência.

05 — CONTEXTO OPERACIONAL DO MVP

O que está travado de propósito na v1

PARÂMETRO	V1
Tipo de pedido	Somente pickup (delivery vem depois).
Pagamento	Na retirada. Sem cartão por telefone (evita complexidade/PCI).
Idiomas	EN / ES / PT no início; crioulo haitiano e italiano conforme validação.
Horário (ET)	Seg–Sex 11:00–14:00 e 17:00–21:00 · Sáb 17:00–21:00 · Dom fechado. Só pedidos ASAP enquanto aberto.
Número	Número dedicado ou encaminhamento parcial do atual.

06 — CRITÉRIOS DE SUCESSO & NÃO OBJETIVOS

Contra o que cada decisão é medida

O MVP É BEM-SUCEDIDO SE, EM CHAMADAS REAIS:

- O cliente liga e é atendido pela IA sem fricção.
- A IA entende o idioma principal do cliente.
- Responde menu, horário, localização e disponibilidade.
- Monta pedido estruturado: itens, modificadores, nome, telefone.
- O pedido chega à operação via bridge, mesmo sem Toast.
- A conversa parece natural o bastante para não prejudicar a marca.
- O tempo de resposta é aceitável em contexto real de telefone.
- A equipe revisa/confirma o pedido sem confusão.
- O custo por chamada/pedido fica numa faixa justificável.
- O sistema recupera pedidos que se perderiam no pico.

O MVP NÃO TENTA RESOLVER (AINDA):

- Pagamento por telefone com cartão.
- Delivery completo com roteirização.
- Dashboard próprio avançado.
- Analytics multi-loja.
- CRM completo.
- Franquia / multi-tenant.
- Substituição total da equipe humana.
- Automação de todos os canais digitais.

Cortar isso do MVP é decisão de foco e de risco: cada item adiado é menos superfície para dar errado antes da prova de receita.

07 — ROADMAP DE CONSTRUÇÃO

Da demo ao produto, em fases de risco crescente

As Fases 0–3 não dependem de ninguém. A Fase 4 (Toast) é a única travada por um terceiro — por isso o acesso deve ser solicitado cedo (ver seção 10).

Fase 0 — Demo funcional QUASE CONCLUÍDA

OBJETIVO

Provar o fluxo técnico fim a fim: cliente fala → IA entende → ferramentas → pedido → total (mock) → confirma → operação.

ENTREGAS

Backend TS + endpoint público · webhook POST /vapi/tool-calls · 5 ferramentas · assistant Vapi · Deepgram (STT) · ElevenLabs (voz) · LLM configurável · testes e build passando · .env · docs (README, ARCHITECTURE, vapi-setup).

CONCLUSÃO

A IA simula uma chamada completa de pedido via Vapi + backend + ferramentas, ainda que em mock/bridge.

Fase 1 — Chamada real (live test)

OBJETIVO

A primeira ligação telefônica real, ponta a ponta: liga → atende → entende idioma → monta pedido → confirma → bridge/SMS → handoff humano.

ENTREGAS

Número Twilio + STORE_TRANSFER_NUMBER + SMS validado · créditos ativos (Vapi/Twilio/LLM/Deepgram/ElevenLabs) · host de teste (tunnel + sync ou já US-East) · assistant “Puccettoni Voice Ordering” com prompt final (marca, idiomas, frase-ponte, handoff, não inventar preço/menu) · voz multilíngue validada (EN/ES/PT, crioulo se possível) · logs e gravações.

CONCLUSÃO

Demonstrar uma chamada real onde a IA atende, conversa, monta pedido estruturado e o envia à operação — sem Toast conectado.

Fase 2 — Bridge operacional real

OBJETIVO

Tornar o sistema utilizável pela loja antes do Toast: o pedido chega claro para alguém executar.

ENTREGAS

Formato padrão do pedido (nome, telefone, idioma, tipo, itens, modificadores, observações, total estimado, status, transcript resumido) · 1 canal principal (**recomendação: SMS + e-mail** ou SMS + impressora) · confirmação interna clara (novo pedido / precisa retornar / lead / fora do cardápio / total estimado vs oficial) · fallback automático (marca toast_fallback, nunca perde pedido).

CONCLUSÃO

Chamada real entra e o pedido chega à operação de forma legível e acionável.

Fase 3 — Infra estável e domínio fixo

OBJETIVO

Sair do tunnel descartável.

ENTREGAS

Backend em host US-East (Render / Railway / Fly.io para MVP) · URL fixa + HTTPS · variáveis configuradas · health check · logs persistentes · deploy previsível · Vapi apontando para a URL fixa (ex.: voice.puccettoni.com/vapi/tool-calls).

CONCLUSÃO

O sistema não depende mais de trycloudflare.com; testes repetíveis sem quebrar a URL das ferramentas.

Fase 4 — Integração Toast DEPENDÊNCIA DE ACESSO À API

DEPENDÊNCIA

Acesso da conta Toast do Marco às APIs necessárias (Menus · Config · Prices · Orders).

FLUXO

Sincronizar menu (Menus V3) → mapear itens/modificadores → montar carrinho do nosso lado → /prices (total oficial) → confirmar → criar pedido (Orders API) → tratar status/erro → falha cai no bridge.

DECISÕES

Toast não é carrinho (o carrinho é nosso) · o preço oficial vem do Toast · horário validado por nós · falha não perde pedido · pagamento fora do MVP (PCI).

CONCLUSÃO

A IA cria pedido real no Toast/KDS ou cai automaticamente no bridge em caso de falha.

Fase 5 — Piloto operacional controlado

ESCOPO

Horários específicos, só pickup, sem pagamento por telefone, sem delivery complexo, handoff fácil. Ex.: 7–14 dias, 11–14h ou 18–21h, EN/ES/PT.

MEDE

Negócio: chamadas atendidas, pedidos capturados, pedidos que se perderiam, ticket médio, receita recuperada, custo/pedido, ROI. **Qualidade:** entendimento por idioma, correção do pedido, tempo de resposta, handoff, abandono, satisfação.

CONCLUSÃO

Provar que o sistema gera receita ou reduz perda operacional sem prejudicar a experiência.

Fase 6 — Otimização (latência, voz, custo)

A/B

LLM: Claude Sonnet / Haiku, GPT-4o mini / 4.1 mini, Gemini Flash — por latência, qualidade, custo, tool-calling e erros por idioma. **Voz:** ElevenLabs Multilingual v2 vs. outras vozes vs. Realtime no inglês vs. vozes por idioma. **Prompt:** respostas curtas, menos tokens, frases-ponte, mais uso de ferramentas, confirmação objetiva.

CONCLUSÃO

O melhor equilíbrio entre qualidade de conversa, latência, custo por pedido e confiabilidade.

Fase 7 — Automação assíncrona (n8n)

USOS

Resumo para a equipe, lead no CRM, follow-up por SMS/e-mail, alertas de pedido perdido, relatórios diários, registro em planilha/dashboard, reativação. **Nunca** para price_cart/submit_order no caminho crítico, nem em turnos com o cliente na linha.

CONCLUSÃO

Automação funcionando sem adicionar latência ao pedido.

Fase 8 — Produto multi-restaurante / franquia

OBJETIVO

Transformar o que funciona na Puccettoni em produto replicável — **só após validar receita na loja.**

ENTREGAS

Multi-store / multi-menu · config por restaurante · dashboard · analytics · billing · permissões · templates de prompt · integrações (Toast / Square / Clover / Olo) · playbook de onboarding · monitoramento robusto · SLA.

CONCLUSÃO

Deixa de ser “projeto Puccettoni” e vira uma plataforma vendável para restaurantes.

08 — MÉTRICAS E MODELO DE CUSTO

O que medir para saber que funciona — e que se paga

MÉTRICAS DE NEGÓCIO

- Chamadas atendidas e pedidos capturados
- Pedidos que **seriam perdidos** sem o sistema
- Ticket médio e **receita recuperada**
- Custo por pedido concluído · ROI estimado
- Tempo de equipe economizado · reclamações

MÉTRICAS DE QUALIDADE / LATÊNCIA

- **Time-to-first-audio** e latência média por turno
- Taxa de entendimento (por idioma)
- Taxa de pedido estruturado corretamente
- Taxa de handoff · abandono
- Satisfação percebida

MODELO DE CUSTO — A MÉTRICA QUE IMPORTA É O CUSTO POR PEDIDO CONCLUÍDO

O custo de uma chamada soma cinco componentes por minuto: **telefonía** (Twilio), **STT** (Deepgram), **LLM** (tokens), **TTS** (ElevenLabs) e **orquestração** (Vapi). Os valores exatos saem do preço vigente de cada provedor e, sobretudo, da **medição no piloto** — por isso não os fixamos aqui. A leitura correta não é o custo por minuto isolado, e sim o **custo por pedido concluído** comparado a (a) a comissão que um app de delivery cobraria e (b) o valor de um pedido que, sem o sistema, simplesmente se perderia. A Fase 6 (A/B de modelo e voz) existe justamente para empurrar esse número para baixo.

09 — RISCOS E MITIGAÇÕES

O que pode dar errado — e como já estamos cobertos

RISCO	SEV.	MITIGAÇÃO
Prazo de acesso à API Toast	Alta	Solicitar o acesso cedo, não na Fase 4. Até liberar, o bridge mantém a operação rodando — o cronograma não trava.
Latência no turno do pedido	Média	Frase-ponte no idioma do cliente, streaming em tudo, host US-East. Medir time-to-first-audio e a duração da chamada ao Toast.
Qualidade multilíngue (esp. crioulo)	Média	ElevenLabs Multilingual v2; A/B medido em crioulo/PT; handoff humano sempre disponível como rede.
Créditos / trial dos provedores	Média	Ativar billing (Twilio, LLM, Vapi) antes da Fase 1; validar limites do trial.
URL instável (quick tunnel)	Baixa	sync-tunnel.mjs no dev; host fixo US-East a partir da Fase 3.
Risco de marca (IA robótica / erro)	Média	Tom curto e humano, confirmação obrigatória, nunca inventar, handoff fácil; piloto em horário controlado.
Over-build (plataforma cedo demais)	Média	Escopo recortado pelos não objetivos; multi-loja/dashboard só após a prova de receita.

10 — PRÓXIMAS AÇÕES

A ordem prática do que fazer

DECISÃO A TOMAR AGORA (DO MARCO)

(1) Liberar a compra de um **número Twilio** e a ativação de créditos; (2) **solicitar o acesso à API Toast** pela conta da Puccettoni já — a aprovação tem prazo variável e é o principal curinga do cronograma, mesmo que a integração só seja construída na Fase 4.

Agora

- Finalizar sync-tunnel.mjs e validar que o Vapi atualiza as URLs das ferramentas automaticamente.
- Comprar/configurar número Twilio · definir TWILIO_PHONE_NUMBER · validar STORE_TRANSFER_NUMBER.
- Fazer a primeira chamada real curta.

Depois da primeira chamada

- Ajustar o prompt pelo transcript · testar EN/ES/PT · testar SMS/bridge real.
- Medir latência e custo · gravar a demo para o Marco.

Antes da operação real

- Subir o backend em host US-East com URL fixa · bridge operacional confiável.
- Definir o processo da loja para receber o pedido · rodar o piloto controlado.

Depois do piloto

- Ativar o acesso à Toast API (já solicitado) · integrar Menus/Prices/Orders · pedidos reais no KDS.
- Otimizar custo, modelo, voz e idiomas (Fase 6).

11 — FECHAMENTO

A tese de receita

Se a IA conseguir atender chamadas reais no pico, entender o cliente em seu idioma, estruturar o pedido e entregá-lo à operação sem perder venda, a Puccettoni ganha um **canal de receita próprio antes mesmo** de integrar completamente com o Toast. A sofisticação vem depois da prova de receita.

Brief executivo · Puccettoni — Plataforma de Atendimento por Voz com IA & CX · arquitetura validada em conjunto. Versões traduzidas (EN/IT) disponíveis sob demanda.